

Nicolás Santiago Moreno Monroy

Desarrollador de IA (AI Engineer) | LLMs, agentes, evaluación, Python

Bucaramanga, Colombia (UTC-5) | Remoto

Email: nm5571762@gmail.com | Tel: +57 350 232 8517

linkedin.com/in/nicolas-moreno-dev | github.com/nicolas2601 | nicolasmoreno.site

PERFIL

Desarrollador de IA aplicada con más de 2 años en Python y TypeScript y un agente LLM en producción atendiendo clientes reales. Ahí aprendí que la confiabilidad la dan los guardrails y las evaluaciones, no el modelo: el código decide, el modelo redacta y nada sale sin validarse.

EXPERIENCIA

Desarrollador de Software e IA aplicada | Freelance, clientes PYME | Ene 2024 – presente

- Llevé a producción un agente LLM de reservas por WhatsApp: el código calcula disponibilidad y precio, el modelo solo redacta, y guardrails deterministas validan cada respuesta antes de enviarla (bloquean fechas ocupadas ofrecidas como libres). Redujo cerca del 80% el tiempo de gestión (Gemini, n8n, PostgreSQL, WhatsApp Cloud API).
- Construí un harness de evaluación con 30 casos que reproduce el pipeline real (datos, modelo, guardrails); con él comparé modelos y variantes de prompt antes de cada cambio en producción, con rollback de modelo en un paso y alertas cuando el flujo falla.
- Entregué APIs REST e integraciones para clientes de logística, salud y comercio, con autenticación JWT/OAuth y validación de entrada (FastAPI, Django, NestJS).

PROYECTOS

- **PromptLab** (Next.js, Vercel AI SDK, Groq): optimizador de prompts multimodal con voz (Whisper) e imagen (modelo de visión), respuestas en streaming y ejecución de prueba contra el modelo real.
- **Tesis en clúster GPU**: aprendizaje autosupervisado para detectar lesiones de piel (PyTorch, SimSiam, DINOv2); entrenamiento distribuido DDP en 2 GPUs RTX PRO 4000 a 420 imágenes/s, con TensorBoard e informe público. Asesoría de KAUST.
- **OmniCoder**: CLI de programación con agentes de IA, publicado en npm como @nicolas2601/omnicoder, con soporte para varios proveedores de LLM (TypeScript, Bun).
- **GobIA Auditor** (Hackathon Colombia 5.0): orquestador de agentes sobre MiniMax M2.7 que audita contratos públicos de SECOP II.
- **Open source**: 3 pull requests aceptados en n8n (~200k estrellas) y umami (~39k): fix del nodo de Jira, enlaces con basePath y cálculo de duración de replays, cada uno con pruebas.

HABILIDADES

LLMs: agentes, tool calling, servidores MCP, guardrails, evaluación de prompts y modelos, streaming

Modelos: Gemini, Claude, GPT-OSS, MiniMax M2, DeepSeek, Qwen, Whisper

Modelos locales y ML: llama.cpp, GGUF cuantizados (Qwen), Ollama, PyTorch, DDP multi-GPU, DINOv2

Ingeniería: Python (FastAPI, Django), TypeScript (Next.js, NestJS), Vercel AI SDK, n8n, PostgreSQL, Docker

EDUCACIÓN

Ingeniería de Sistemas, Universidad Autónoma de Bucaramanga (UNAB). 8.º semestre, grado esperado en 2027.

Primer puesto regional y finalista nacional, Hackathon Colombia 5.0 (MinTIC), 2026.

IDIOMAS

Español nativo. Inglés B1: lectura técnica fluida y escritura diaria en trabajo remoto.